Projekt Data Science:

Maskininlärning för binär klassificering

Prediktiv och statistisk analys av diabetesdata i ett obalanserat dataset



ECUTBILDNING

Katarina Persson
Data Scientist, EC-Utbildning
Data science projekt
2026-10-11

Abstract

This project evaluates the performance of several machine learning models for predicting diabetes using a synthetic dataset commonly employed in educational settings. Because the dataset lacks clinical context and contains medically unrealistic values, the results are not generalizable to real patient populations. The study focuses on methodological comparison rather than clinical inference. Exploratory data analysis, data preprocessing, and evaluation of five classification models — Logistic Regression, Random Forest, HistGradientBoosting, CatBoost, and a VotingClassifier ensemble — were conducted. Particular attention was given to the severe class imbalance (8.5% positive cases), which makes accuracy a misleading metric.

The Optuna-optimized CatBoost model without class weighting achieved the best overall performance, with a peak F2-score of 0.800 at a decision threshold of 0.15 (recall 85.8%, precision 62.8%) and a ROC-AUC of 0.981. Cross-validation (5-fold) confirmed stable performance across data splits (macro-F1: 0.785 ± 0.004). A VotingClassifier ensemble of all 4 models evaluated, but it did not outperform CatBoost, indicating that combining related tree-based models provides limited ensemble gain.
The findings suggest that threshold tuning combined with appropriate model selection could improve the practical performance of classifiers trained on imbalanced datasets

Innehållsförteckning

Abstract 1
1.0 Inledning 3
1.1 Syfte 4
1.2 Frågeställningar 4
1.3 Metodöversikt 4
1.3.1 Datamaterial och förberedelser 4
1.3.2 Train/testupplägg 5
1.3.3 Statistisk utvärdering 5
1.3.4 Agilt arbetssätt 5
2.0 Teori 5
2.1 Modellens statistiska utvärdering 6
3.0 Metod 6
3.1 Dataset information 6
3.2 Data pre-processing 7
3.3 Datasetets variabler 7
3.4 Datainsamling 8
3.5 EDA - Data set Kaggle Diabetes 8
3.6 Dataförbehandling 9
3.7 Fördelning datasetet –numeriska variablerna 9
3.8 Skevhet i numeriska variabler 11
3.9 Målvariabler Y 12
3.10 Undersökning; korrelation mellan variabler (X–X) och målvariabeln (Y–X) 12
3.11 Samlad tolkning 13
3.12 Modellering 14
3.12.1 Modellval för binär klassifikation 14
3.12.2 Optunaoptimering 15
3.12.3 Ensemblemetod: VotingClassifier (majoritetsröstning) 16
3.12.4 Valideringsstrategi 16
3.12.5 Agile arbetsmetod 17
4.0 Resultat 17
Tabell 1: Initial jämförelse baserat på accuracy 18

4.1 Hantering av klassobalans via balanserade klassvikter 18
4.2 Sammanfattande resultat 19
4.3 Variabelbetydelse (Feature Importance) 20
4.4 Cross-validation och stabilitetsanalys för CatBoost 20
4.5 Besvarande av frågeställningar 22
5.0 Diskussion 22
6.0 Slutsats 23

1.0 Inledning

I sin innersta beståndsdel vilar modern maskininlärning på binära strukturer. Från Booles logiska algebra till de statistiska modellerna för sannolikhetsbaserade beslut under 1900-talet har binära representationer utgjort fundamentet för klassificering, optimering och prediktion.

Denna struktur återkommer i en rad tillämpningsområden: inom finans för kreditrisk och default-sannolikhet, inom affärsanalys och marknadsföring för kundbeteende, churn-prediktion och kampanjrespons, inom marknadsanalys för segmentering och sannolikheten att en kund konverterar, och inom medicinska studier för att uppskatta sannolikheten för sjukdom eller behandlingsutfall.

En särskild utmaning uppstår när datasetet är kraftigt obalanserat, eftersom traditionella prestandamått som accuracy då har en tendens att ge missvisande resultat. Detta projekt undersöker hur olika binära klassificeringsmodeller hanterar just denna situation. Arbetet genomförs i en iterativ och utforskande process där teori, implementation och analys utvecklas i korta cykler.

1.1 Syfte

Projektet har som mål att undersöka hur olika binära klassificeringsmodeller presterar på ett syntetiskt dataset genom att använda etablerade maskininlärningsbibliotek i Python. Projektet fokuserar på att jämföra modellernas beteende, utvärdera prestanda med statistiska mått och analysera hur hyperparametrar påverkar resultatet.

1.2 Frågeställningar

För att uppfylla syftet utgår projektet från följande frågor:

- Hur presterar binära klassificeringsmodeller på ett obalanserat, syntetiskt dataset, med fokus på hur klassobalansen påverkar valet av utvärderingsmått och beslutströskel.

- Hur påverkar klassobalansen modellernas precision, recall, F1-värde och ROC-AUC, och vilka mått ger en rättvis bild av prestandan?

1.3 Metodöversikt

Projektet använder scikit-learns etablerade klassificeringsmodeller. Hyperparametrar optimeras med Optuna för att effektivt söka efter stabila och prestandamässigt starka konfigurationer. Fokus ligger på att analysera modellernas beteende, jämföra resultat och visualisera prestanda genom ROC-kurvor, confusion matrices och statistiska mått.

1.3.1 Datamaterial och förberedelser

Som empiriskt underlag används Diabetes Prediction Dataset från Kaggle, vilket lämpar sig väl för binär klassificering eftersom utfallet naturligt kan modelleras som en sannolikhet mellan 0 och 1. Datat genomgår grundläggande EDA, rensning och variabelhantering för att säkerställa att modellerna kan utvärderas på ett jämförbart sätt.

1.3.2 Train/test-upplägg

Datasetet delades upp i 70% träning, 15% validering och 15% test, med stratifiering för att bevara klassfördelningen. Valideringsdelen användes för hyperparameteroptimering och tröskelanalys, medan testdelen hölls helt separat för slutlig verifiering.

1.3.3 Statistisk utvärdering

Modellernas prestanda utvärderas med hjälp av mått såsom noggrannhet, precision, recall, F1-värde och ROC-kurvor. För den bäst presterande modellen beräknas även konfidens-intervall för centrala prestandamått, i syfte att kvantifiera osäkerheten och bedöma modellens stabilitet över olika datadelningar.

1.3.4 Agilt arbetssätt

Arbetet i projektet följde en iterativ struktur inspirerad av Scrum och Agile. Varje modellutvecklingscykel fungerade som en “sprint” där följande moment genomfördes:

2.0 Teori

2.1 Modellens statistiska utvärdering

Statistiska beräkningar används för att visa att en maskininlärningsmodell inte presterar bra av slumpen, utan uppvisar stabil och reproducerbar prestanda över flera oberoende data-delningar. Train/test-split säkerställer att modellen utvärderas på data den inte har sett tidigare, vilket minskar risken för att resultaten beror på slumpmässiga variationer i träningsdata, och för att undvika överanpassning.

Till skillnad från klassisk statistik, som ofta bygger på antaganden om fördelningar och signifikansnivåer, fokuserar maskininlärning på modellens generaliseringsförmåga och hur väl den presterar på tidigare osedd data.

Cross-validation är därför standard inom ML, eftersom det ger en empirisk bedömning av modellens stabilitet genom att utvärdera den på flera separata folds. Detta är särskilt viktigt vid klassobalans, där en enskild train/test-split kan ge en missvisande bild av modellens förmåga att identifiera minoritetsklassen.

I ML är stabilitet över folds viktigare än p-värden, eftersom p-värden förutsätter statistiska antaganden som sällan gäller för komplexa, icke-linjära modeller. En modell anses statistiskt säkerställd när den uppvisar konsekventa värden för precision, recall, F1 och ROC-AUC över flera datadelningar, snarare än när en enskild testning råkar ge ett högt resultat.

3.0 Metod

I detta data science-projekt har jag utvecklat, tränat och utvärderat ett antal maskin-inlärningsmodeller inom området binär klassificering. Syftet är att undersöka hur olika modeller presterar vid prediktion av diabetes baserat på medicinska variabler.

I studien används fem modeller för binär klassificering: Logistic Regression (baseline), Random Forest, Histogram Gradient Boosting, CatBoost samt en VotingClassifier-ensemble. Dessa modeller representerar både linjära metoder och avancerade träd-baserade algoritmer, vilket ger en bred och jämförbar portfölj för analys av tabulär hälsodata.

3.1 Dataset information

Datasetet som används i projektet är hämtat från Kaggle och består av strukturerade observationsdata kopplade till diabetesdiagnostik. Det är syntetiskt genererat för undervisning och maskininlärningsexperiment, och efterliknar strukturen hos kliniska data utan att representera verkliga patienter eller medicinskt validerade samband.

Datasetet saknar information om geografiskt ursprung, insamlingsår och klinisk kontext, och flera oberoende granskningar har visat att det innehåller värden som är medicinskt osannolika. Exempelvis förekommer BMI-värden utanför det intervall som observerats i stora kliniska kohorter såsom UK Biobank, och HbA1c-värden är trunkerade vid 9 trots att högre värden är vanliga i verkliga journaldata.

Datasetet är omnämnt i en Nature-artikel där det avråds från användning i vetenskapliga publikationer. Däremot är det ett vanligt och uppskattat dataset inom utbildning, eftersom det är rent, komplett och lätt att arbeta med. I denna studie används datasetet därför som

ett metodologiskt exempel för att jämföra olika maskininlärningsmodeller, snarare än för att dra kliniska slutsatser eller göra medicinska tolkningar.

3.2 Data pre-processing

Data pre-processing genomfördes för att säkerställa att datasetet var konsistent och direkt användbart för modellering. I datasetet fanns inga saknade värden, inkonsekventa format eller outliers i anmärkningsvärd mängd, vilket innebär att imputation eller avancerad datarensning krävdes. Samtliga variabler kunde användas ursprungliga form.

Ingen standardisering eller normalisering utfördes, då detta främst gynnar linjära modeller och distansbaserade algoritmer. I detta projekt utgör logistisk regression endast en baseline, medan huvudmodellerna är trädbaserade och därmed okänsliga för variabelskalor.

EDA-analysen bekräftar datasetets syntetiska natur, bland annat genom låga korrelationer mellan variabler och avsaknad av medicinskt rimliga samband i vissa kategoriska features. Detta är en viktig metodologisk insikt, eftersom det innebär att resultaten främst ska tolkas som en jämförelse mellan modeller, snarare än som en prediktiv analys av diabetesrisk i en verklig population.

Kategoriska variabler kodades med one-hot-encoding, vilket är lämpligt för träd-baserade modeller och ensemblemetoder som inte kräver ordnade kategorier.

Train/test-split genomfördes med en sedvanliga 70/15/15-fördelning, vilket ger en tillräckligt stor träningsmängd för hyperparameteroptimering och en stabil testmängd för utvärdering. Den kraftiga klassobalansen (8,5 % positiva fall) beaktades genom att utvärderingsmåtten fokuserade på recall, precision, F1 och ROC-AUC snarare än accuracy.

Pre-processing-steget säkerställer därmed att datasetet är konsekvent, korrekt kodad och direkt användbart för modellering, samtidigt som det bibehåller datasetets syntetiska struktur för metodjämförelsen.

SMOTE användes inte i detta projekt. Eftersom datasetet är syntetiskt och projektets syfte är att jämföra modellernas naturliga beteende under klassobalans, skulle syntetisk upp-sampling riskera att introducera artificiella mönster och påverka modellernas stabilitet. Klassobalansen hanterades istället med modellparametern class weight ' i de modeller som stödjer detta, vilket är metodologiskt mer lämpligt i denna kontext.

Till modellen Random forest användes en mer avancerad inställning Class weight, balanced subsample, vilket innebär att klassvikterna beräknas dynamiskt och unikt för varje enskilt beslutsträds bootstrap-urval. Detta minskar risken för att individuella träd under träningen domineras helt av majoritetsklassen.

Ingen feature engineering genomfördes eftersom datasetet är syntetiskt och saknar domänspecifik struktur som skulle motivera nya variabler. Fokus ligger istället på att utvärdera modellernas prestanda på datasetets ursprungliga features.

3.3 Datasetets variabler

Datasetet innehåller nio variabler som beskriver grundläggande demografiska och medicinska faktorer, och men sammanfattas här nedan:

- **gender** – individens kön

- **age** – ålder i år
- **hypertension** – förekomst av högt blodtryck (0 = nej, 1 = ja)
- **heart_disease** – förekomst av hjärtsjukdom (0/1)
- **smoking_history** – kategorisk variabel som anger rökvanor
- **bmi** – kroppsmassindex
- **HbA1c_level** – genomsnittlig blodsockernivå över tid
- **blood_glucose_level** – aktuell blodsockernivå vid mätning
- **diabetes** – målvariabeln (0 = ingen diabetes, 1 = diabetes)

3.4 Datainsamling

Datasetet som används i projektet hämtades från Kaggle, där det tillgängliggjorts som en öppen CSV-fil. Filen laddades ner manuellt via Kaggle-plattformen och importerades därefter till Python för vidare analys. Datainläsningen genomfördes med hjälp av Pandas, Python bibliotek för datahantering, vilket möjliggjorde strukturerad bearbetning och förberedelse av datasetet inför modelleringen.

3.5 EDA - Data set Kaggle Diabetes

För att ge en överblick över datasetets struktur visas nedan de första raderna (head). Datasetet består av 100 000 observationer och 9 variabler, där varje rad representerar en individ och varje kolumn en medicinsk variabel kopplad till diabetesdiagnostik.

gender	age	Hyper tension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucos
Female	80	0	1	never	25.19	6.6	
Female	54	0	0	No Info	27.32	6.6	
Male	28	0	0	never	27.32	5.7	
Female	36	0	0	current	23.45	5	
Male	76	1	1	current	20.14	4.8	

	Column	Non-null	Nulls	Unique	Dtype
0	gender	100000	0	3	object
1	age	100000	0	102	float64
2	hypertension	100000	0	2	int64
3	heart_disease	100000	0	2	int64
4	smoking_history	100000	0	6	object
5	bmi	100000	0	4247	float64
6	HbA1c_level	100000	0	18	float64
7	blood_glucose_level	100000	0	18	int64
8	diabetes	100000	0	2	int64

3.6 Dataförbehandling

Dataset diabetes innehåller inga saknade värden

variable	missing_values
gender	0
age	0
hypertension	0
heart_disease	0
smoking_history	0
bmi	0
HbA1c_level	0
blood_glucose_level	0
diabetes	0

Kategoriska variabler

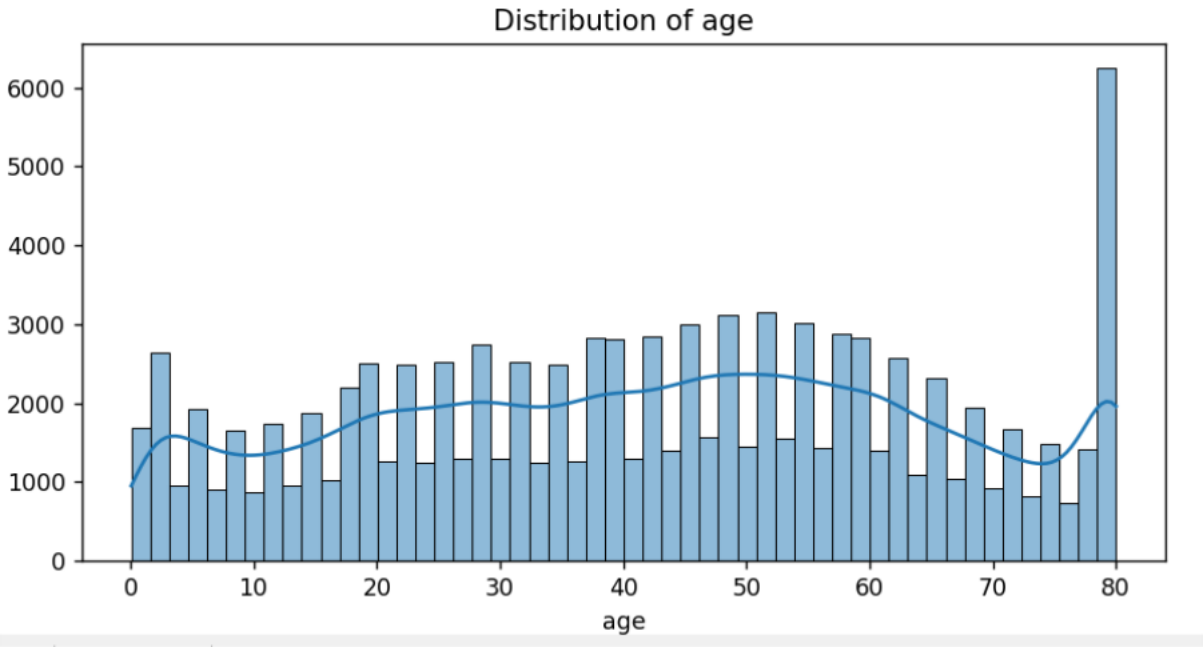
Datasetet innehåller två kategoriska variabler: gender och smoking_history.

['Female' 'Male' 'Other']

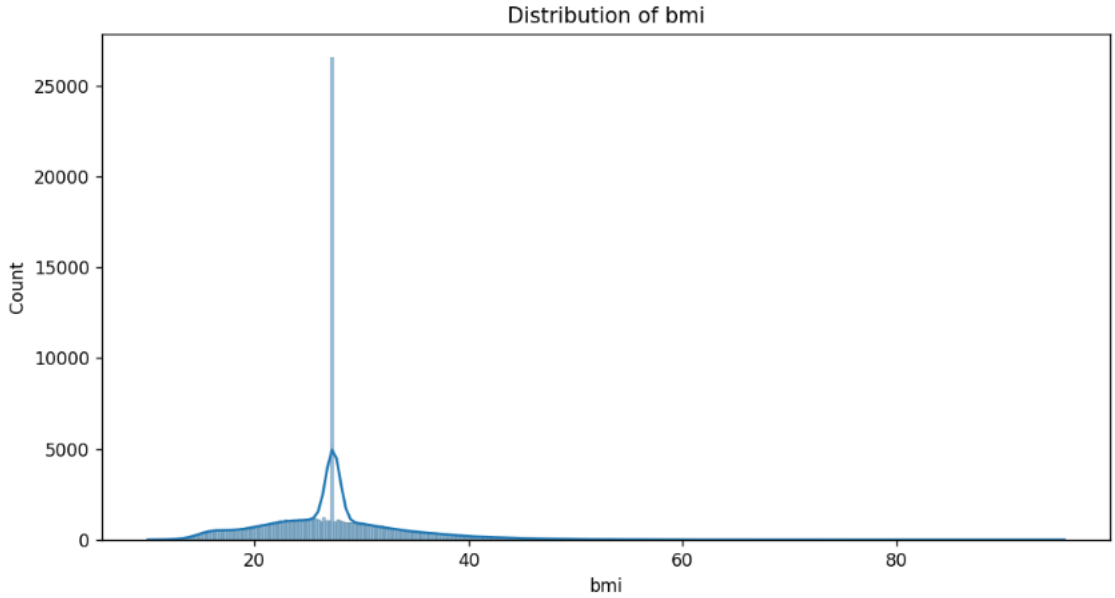
['never' 'No Info' 'current' 'former' 'ever' 'not current']

Dessa kodades om till numeriska representationer för att kunna användas i maskininlärningsmodeller. One-hot encoding användes för att skapa binära indikatorvariabler för respektive kategori, vilket förhindrar att modellerna tolkar kategorierna som ordnade.

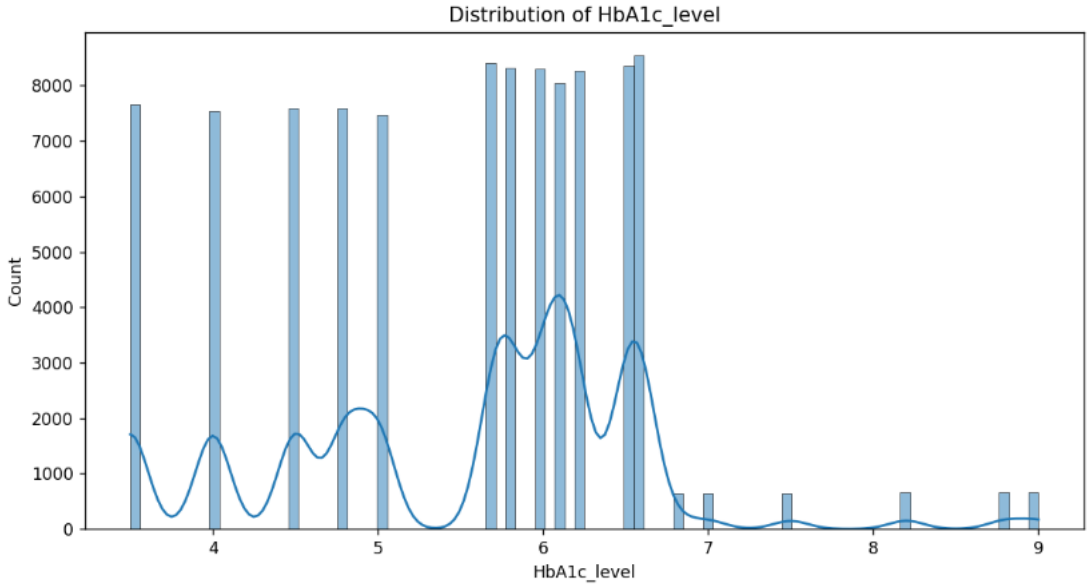
3.7 Fördelning datasetet –numeriska variablerna



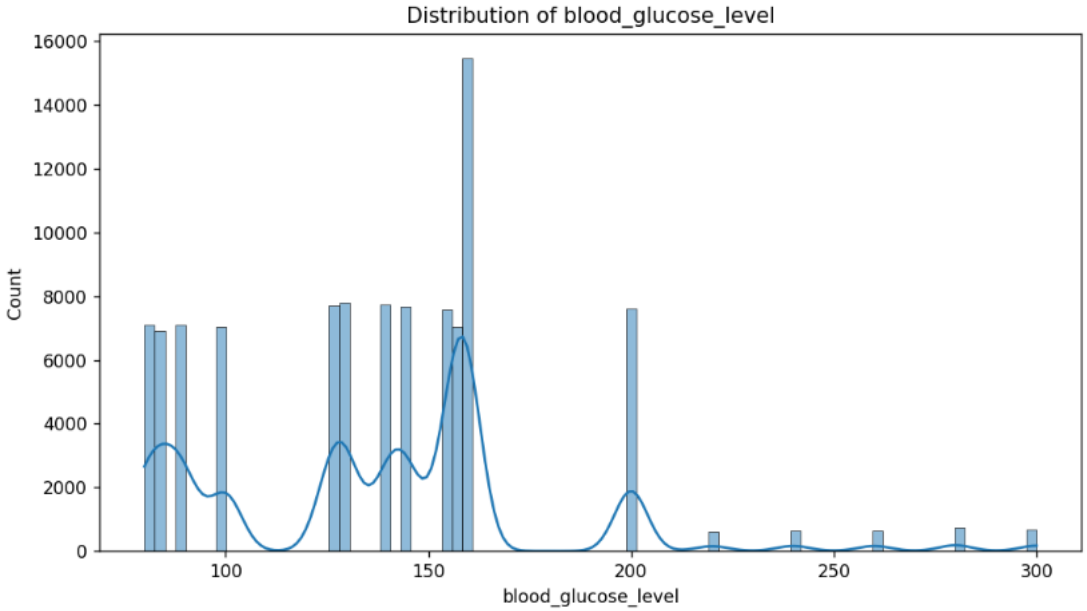
Histogrammet visar att datasetet innehåller individer från 0 till 80 år. Eftersom datasetet är syntetiskt genererat förekommer även mycket unga individer, vilket inte nödvändigtvis speglar en kliniskt realistisk population, men uppfattades inte ge några problem vid analys.



Histogrammet visar att BMI är approximativt normalfördelat med en tydlig topp runt 25, vilket är förväntat i både verkliga och syntetiskt genererade hälsodata. Fördelningen är något högerskev med en svans av högre värden, vilket är vanligt för BMI-variabler. Några extremvärden förekommer, men dessa påverkar inte helhetsbilden i någon nämnvärd omfattning.



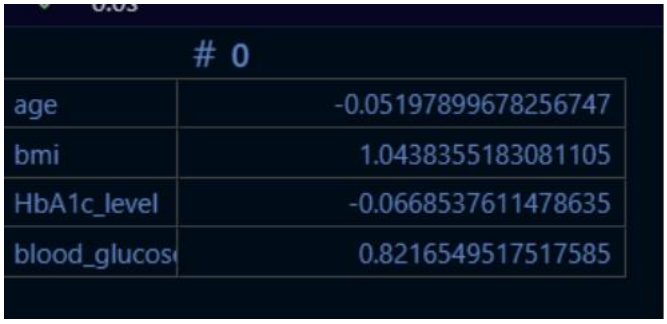
HbA1c-fördelning Histogrammet visar att HbA1c inte är normalfördelad utan uppvisar flera toppar. Detta är förväntat eftersom HbA1c speglar olika metabola tillstånd (frisk, prediabetes och diabetes). Fördelningen är därför naturligt klustrad och varierande, vilket är vanligt både i verkliga och syntetiskt genererade hälsodata.



Blodsockernivåer Fördelningen av blood_glucose_level är tydligt multimodal och saknar en enkel, normalfördelad form. Detta är förväntat eftersom blodsocker påverkas av många faktorer såsom måltider, medicinering och diabetesstatus. Histogrammet visar flera toppar, bland annat en större koncentration runt 160, vilket speglar variationen mellan olika metabola tillstånd i datasetet.

3.8 Skevhet i numeriska variabler

För att komplettera de visuella distributionerna analyserades skevheten i de numeriska variablerna. Detta ger en indikation på hur symmetriska eller snedfördelade variablerna är, vilket är relevant inför modellering.



	# 0
age	-0.05197899678256747
bmi	1.0438355183081105
HbA1c_level	-0.0668537611478635
blood_glucos	0.8216549517517585

För att komplettera de visuella distributionerna analyserades skevheten (skewness) i de numeriska variablerna. Detta ger en indikation på hur symmetriska eller snedfördelade variablerna är inför modelleringen. Ålder –0, 05 och HbA1c-nivå –0,06 uppvisar en närmast perfekt symmetrisk fördelning nära noll. BMI 1,04 och blodsocker 0,82 uppvisar däremot en måttlig till markant högerskevhet med längre svansar mot högre värden, vilket är ett vanligt och förväntat mönster i hälso- och livsstilsdata.

3.9 Målvariabler Y

Målvariabeln Y representerar modellens utfallsvariabel och anger om diabetes anses föreligga eller inte. Variabeln är binär och kategorisk, där varje observation tillhör en av två möjliga klasser:

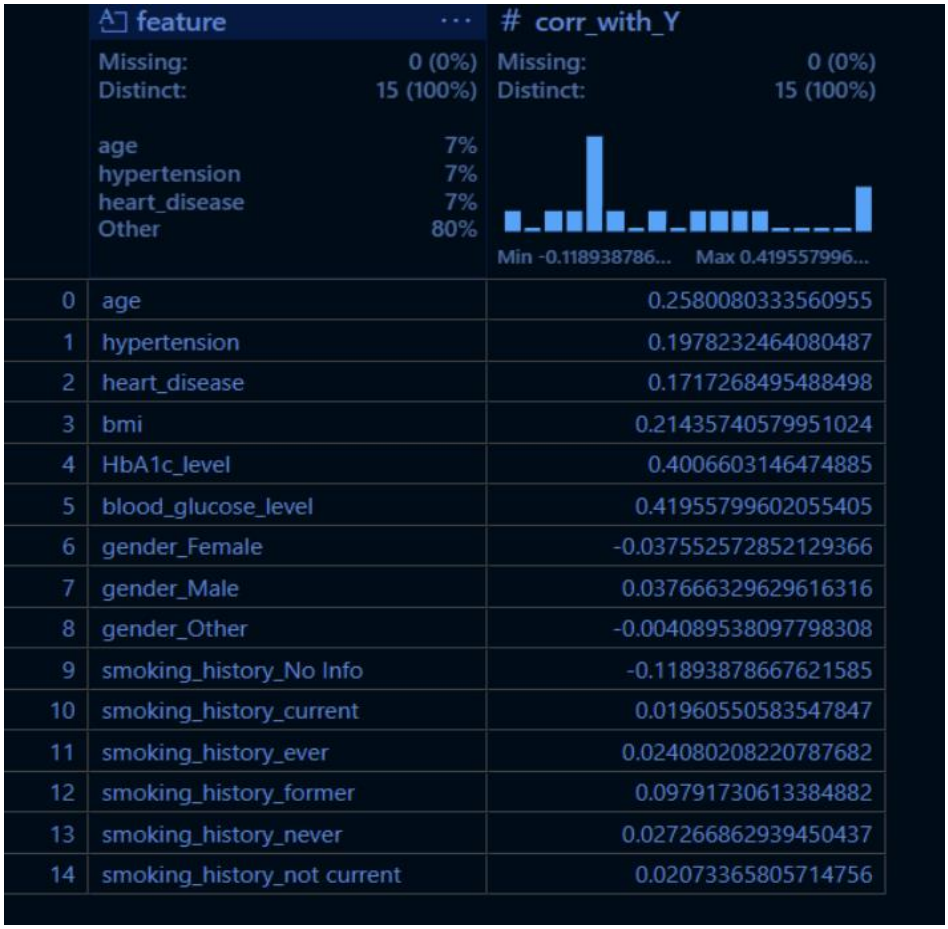
- 1 — diabetes föreligger
- 0 — diabetes föreligger inte

I en klassificeringsmodell innebär detta att modellen beräknar ett estimerat sannolikhets-värde *P^(Y=1/X)* som anger hur sannolikt det är att en individ tillhör klass 1 givet sina observerade egenskaper *X*.

Enligt beslutsteori för binär klassificering vid kraftig klassobalans bör den optimala tröskeln ligga nära prioren för den positiva klassen (8,5 %). I resultatdelen genomförs därför en systematisk, empirisk utvärdering runt dessa lägre nivåer (från 0,50 ner till 0,10) för att identifiera den brytpunkt som maximerar screeningverktygets kliniska tillförlitlighet via F2-score.

Målvariabeln Y uppvisar en kraftig klassobalans, där 91 % av observationerna tillhör klass 0 och endast 8,5 % tillhör klass 1. Eftersom datasetet uppvisar en kraftig klassobalans där enbart 8,5 % av observationerna tillhör klass 1.

3.10 Undersökning; korrelation mellan variabler (X–X) och målvariabeln (Y–X)



	feature	corr_with_Y
	Missing: 0 (0%) Distinct: 15 (100%)	Missing: 0 (0%) Distinct: 15 (100%)
	age 7% hypertension 7% heart_disease 7% Other 80%	Min -0.118938786... Max 0.419557996...
0	age	0.2580080333560955
1	hypertension	0.1978232464080487
2	heart_disease	0.1717268495488498
3	bmi	0.21435740579951024
4	HbA1c_level	0.4006603146474885
5	blood_glucose_level	0.41955799602055405
6	gender_Female	-0.037552572852129366
7	gender_Male	0.037666329629616316
8	gender_Other	-0.004089538097798308
9	smoking_history_No Info	-0.11893878667621585
10	smoking_history_current	0.01960550583547847
11	smoking_history_ever	0.024080208220787682
12	smoking_history_former	0.09791730613384882
13	smoking_history_never	0.027266862939450437
14	smoking_history_not current	0.02073365805714756

Tabellen visar sambandet mellan varje prediktor och målvariabeln *diabetes* (Y). Syftet är att identifiera vilka variabler som har starkast linjära samband med utfallet och därmed förväntas vara mest informativa i modelleringen.

De två starkaste korrelationerna återfinns för:

- blood_glucose_level (r ≈ 0.42)
- HbA1c_level (r ≈ 0.40)

Båda är medicinskt välmotiverade indikatorer på diabetes och förväntas därför vara centrala prediktorer. Variabler som age, bmi, hypertension och heart_disease uppvisar måttliga positiva samband (r ≈ 0.17–0.26), vilket tyder på att de bidrar med relevant men mindre stark information.

De kategoriska variablerna (efter one-hot encoding) visar generellt svaga korrelationer, vilket är normalt eftersom dummyvariabler ofta fångar mer subtila mönster som inte nödvändigtvis uttrycks linjärt.

Den enda svagt negativa korrelationen är smoking_history_No *Info*, vilket sannolikt speglar datasetets struktur snarare än ett verkligt skyddande samband.

3.11 Samlad tolkning

- De medicinska variablerna relaterade till glukosmetabolism är tydligt mest informativa.
- Övriga numeriska variabler bidrar med kompletterande men svagare signal.
- Dummyvariablerna har låg korrelation, vilket är förväntat och inte problematiskt.
- Ingen variabel uppvisar extremt hög korrelation med Y, vilket innebär att modellerna inte riskerar att domineras av en enskild prediktor

	feature	# corr_with_Y
	Missing: 0 (0%)	Missing: 0 (0%)
	Distinct: 7 (100%)	Distinct: 7 (100%)
	age 14%	
	hypertension 14%	
	heart_disease 14%	
	Other 57%	
		Min -0.118938786... Max 0.419557996...
0	age	0.2580080333560955
1	hypertension	0.1978232464080487
2	heart_disease	0.1717268495488498
3	bmi	0.214357405799510 24
4	HbA1c_level	0.4006603146474885
5	blood_glucose_level	0.41955799602055405
9	smoking_history_No Info	-0.11893878667621585

Resultaten visar att blood_glucose_level och HbA1c_level har de starkaste sambanden med Y, följt av age, bmi, hypertension och heart_disease. Dessa variabler förväntas därför vara mest informativa i modelleringen. Övriga variabler uppvisar korrelationer nära noll, vilket är förväntat för dummyvariabler och innebär att deras relation till Y sannolikt fångas bättre av icke-linjära modeller än av linjära mått som Pearson-korrelation.

3.12 Modellering

3.12.1 Modellval för binär klassifikation

I projektet används flera modeller för binär klassifikation, med syftet att jämföra både klassiska maskininlärningsmetoder och mer avancerade ensemble alternativ. Binär klassifikation innebär att modellen ska förutsäga ett av två möjliga utfall (0/1), vilket är vanligt i medicinska, ekonomiska och riskrelaterade prediktionsproblem. Modellvalet omfattar olika metoder för att få en bred bild av prediktionsprestanda, stabilitet och osäkerhet.

Logistic Regression (LR) valdes som en linjär baseline-modell. Den är enkel, transparent och fungerar som en referenspunkt för att bedöma om mer komplexa modeller tillför faktisk prediktionsförbättring. LR är dessutom standard inom binär klassificering och ger tydliga sannolikhetsbaserade prediktioner.

Random Forest (RF) valdes som en robust ensemblemodell som kombinerar många beslutsträd. RF är motståndskraftig mot brus, hanterar icke-linjära samband och fungerar väl på dataset med blandade variabeltyper. Den ger också feature importance som är lätt att tolka, vilket är värdefullt i metodologiska jämförelser.

Histogram Gradient Boosting (HGB) valdes som en modern gradientboostad modell som är optimerad för hastighet och prestanda. HGB hanterar icke-linjära samband effektivt och presterar ofta bättre än RF på syntetiska dataset där gradientinformation är mer informativ än slumpmässiga träd. Den är särskilt lämplig när datan är ren och välstrukturerad.

CatBoost valdes för att representera en avancerad gradientboostad metod med symmetriska träd och stark regularisering. CatBoost är känd för stabil prestanda, god hantering av interaktioner och förmåga att upptäcka komplexa mönster. Den kompletterar HGB genom att ofta hitta andra typer av signaler i datan.

Voting Classifier: ensemblemetod där flera klassificeringsmodeller röstar om det slutliga utfallet. I projektet används soft voting, vilket innebär att varje modell bidrar med sina prediktionssannolikheter och att det slutliga beslutet baseras på den sammanlagda sannolikhetsfördelningen. Detta är särskilt relevant i ett syntetiskt dataset där olika modeller kan fånga olika aspekter av datagenereringen.

Utöver de individuella modellerna utvärderades en varianter av VotingClassifier-ensembler: med samtliga modeller, men den överträffade inte CatBoost, vilket motiverade att inte inkludera ensemblemetoden som slutmodell.

Genom att kombinera modeller med olika egenskaper minskar risken att en enskild modell dominerar beslutsgränsen. Soft voting ger dessutom mer stabila prediktioner än hard voting, eftersom sannolikhetsinformation från varje modell vägs in. Genom att sammanväga de individuella modellerna skapar ensemblemetoden en mer robust helhetsbedömning av klassificeringsproblemet.

Genom att kombinera dessa modeller kan projektet analysera skillnader i prediktions-förmåga, tolkningsbarhet och osäkerhet. Tillsammans ger dessa fem modeller en bred och metodologiskt motiverad jämförelse som belyser hur olika maskininlärningsstrategier beter sig i ett kontrollerat, syntetiskt datarum.

Samtliga modeller tränades på en 70/15/15 -fördelning av datasetet och utvärderades med både övergripande score-mått och detaljerade classification reports för att säkerställa en konsekvent och jämförbar prestanda. Samtliga modeller byggdes i en pipeline-struktur där pre-processing och modellsteg integrerades, och både tränade modeller samt de Optuna-optimerade versionerna sparades som .pkl-filer med joblib för reproducerbarhet och vidare analys.

3.12.2 Optuna-optimering

För att förbättra modellernas prestanda och säkerställa stabila hyperparametrar användes Optuna, ett modernt ramverk för automatiserad hyperparameteroptimering. Optuna bygger på en effektiv sökstrategi där hyperparametrar testas iterativt och utvärderas med en objektiv funktion som definierar modellens prestanda. I detta projekt användes F1-värdet för den positiva klassen som objektiv funktion, eftersom datasetet uppvisar kraftig klassobalans och F1 ger en mer rättvis avvägning mellan precision och recall.

Optuna använder Tree-Structured Parzen Estimator (TPE) som sökalgoritm. TPE är en bayesiansk metod som modellerar sannolikheten för att olika hyperparametrar leder till goda resultat och styr sökningen mot lovande områden i hyperparameterrummet. Detta gör optimeringen betydligt mer effektiv än grid search eller random search, särskilt för modeller med många parametrar.

Hyperparametrar optimerades för Histogram Gradient Boosting, Random Forest och CatBoost. Dessa modeller har komplexa och icke-linjära beslutsstrukturer där hyperparametrar som max_depth, learning_rate, min_samples_leaf, l2-regularization och antal träd har stor påverkan på modellens beteende. Optimering är därför nödvändig för att undvika överfitting, förbättra generaliserbarhet och säkerställa att modellerna presterar stabilt över olika datadelningar.

Optuna kördes med ett begränsat antal trials för att balansera optimeringskvalitet och beräkningstid. En ConvergenceStopper användes för att avsluta studien när flera efterföljande trials inte gav någon meningsfull förbättring, vilket säkerställde en effektiv och resursbesparande optimeringsprocess. De bästa hyperparametrarna sparades och användes i den slutliga modellutvärderingen samt i VotingClassifier-ensemblen.

3.12.3 Ensemblemetod: VotingClassifier (majoritetsröstning)

Ensemblemetoder ger ökad stabilitet eftersom olika modeller fångar olika mönster i datan. Genom att kombinera flera optimerade modeller minskar risken att en enskild modell överanpassar sig till specifika datadelningar eller brus i datasetet. VotingClassifier fungerar därför som en robust slutmodell som balanserar modellernas individuella svagheter och förstärker deras styrkor.

3.12.4 Valideringsstrategi

Utöver den separata testdelen användes 5-fold cross-validation för att analysera modellernas stabilitet över olika datadelningar. Cross-validation är särskilt viktigt vid klassobalans eftersom en enskild train/test-split kan ge en missvisande bild av modellens förmåga att identifiera minoritetsklassen. Genom att utvärdera modellerna över flera folds minskas risken att resultaten påverkas av slumpmässiga variationer i datan.

Alla modeller utvärderades med samma uppsättning metrics: precision, recall, F1-score och ROC-AUC. Dessa mått ger en mer nyanserad bild av prestandan än accuracy, särskilt när klasserna är obalanserade. Precision och recall fångar modellens beteende för minoritetsklassen, F1 balanserar dessa två, och ROC-AUC visar modellens separations-förmåga över olika tröskelvärden.

Optuna-optimeringen kördes separat för samtliga fyra modeller, och optimerade modellerna sparades i pipeline-form som i pkl-format.

EDA-analysen identifierade flera statistiska egenskaper i datasetet som har direkt metodologisk betydelse för modellvalet. HbA1c och blood_glucose_level uppvisar tydlig multimodalitet, vilket antyder att populationen kan bestå av undergrupper med olika metabola profiler. Samtidigt visar BMI och Age en markant skevhet. Dessa fördelnings-

mönster innebär att linjära modeller, såsom logistisk regression, får svårare att etablera en stabil och generaliserbar beslutsgräns. Träd-baserade modeller hanterar däremot både multimodalitet och skevhet på ett robust och icke-linjärt sätt, vilket gör dem särskilt lämpliga för detta dataset.

Korrelationsanalysen visar dessutom generellt låga samband mellan variablerna, vilket är typiskt för syntetiskt genererade dataset där relationerna inte följer naturliga medicinska eller biologiska mönster. Låga korrelationer innebär att ingen enskild prediktor dominerar modellens beslut, vilket gör ensemblemetoder särskilt effektiva eftersom de kan kombinera flera svaga signaler till en mer stabil och generaliserbar prediktion.

Sammantaget motiverar dessa EDA-fynd användningen av trädmodeller (Random Forest, Histogram Gradient Boosting, CatBoost) samt en VotingClassifier-ensemble, då dessa metoder är väl anpassade för dataset med multimodalitet, skevhet och svaga linjära samband.

Eftersom datasetet är kraftigt obalanserat analyserades flera beslutströsklar empiriskt. Syftet var att undersöka hur förändringar i tröskelvärdet påverkar balansen mellan precision och recall. Standardtröskeln 0,5 används som utgångspunkt, medan lägre trösklar analyseras för att undersöka om recall kan förbättras utan att precisionen försämras alltför kraftigt. EDA visar en kraftig klassobalans (8,5 % positiva fall), vilket kräver att utvärderingen fokuserar på recall, precision, F1 och ROC-AUC snarare än accuracy.

3.12.5 Agile arbetsmetod

Sprint Planning / Analyse: Datasetet analyserades, relevanta variabler identifierades och mål för nästa iteration formulerades.

Generate / Sprint Execution: Modellerna (LR, RF, HGB och CatBoost) tränades och Optuna-optimeringar genomfördes för de modeller som hade komplexa hyperparametrar.

Inspection / Learn: Modellerna utvärderades med 5-fold cross-validation, ROC-kurvor och F1-score för att bedöma stabilitet och generaliseringsförmåga.

Adaptation / Iterate: Resultaten användes för att justera hyperparametrar, välja bort svagare modeller och successivt bygga upp en VotingClassifier-ensemble.

Sprint Review: Modellernas helhetsprestation analyserades för att avgöra vilka som skulle ingå i slutmodellen.

Sprint Retrospective: Efter varje iteration reflekterades över vad som fungerade bra, vad som behövde förbättras och hur nästa steg skulle struktureras.

Denna iterativa process gjorde att projektet utvecklades stegvis, med tydliga mål, kontinuerlig förbättring och en slutmodell som var både stabil och välmotiverad.

Arbetet genomförs iterativt i korta cykler, vilket möjliggör snabb återkoppling mellan teori och praktik och är särskilt värdefullt i experimenten med ensemblemodeller.

4.0 Resultat

För att utvärdera modellernas prediktionsförmåga analyserades ett antal prestandamått, accuracy, precision, recall och F1-score. Eftersom studiens syfte var att identifiera så många positiva observationer som möjligt gavs särskild vikt åt recall, vilket mäter andelen korrekt

identifierade positiva observationer. I en första modellkörning användes Accuracy som ett övergripande mått på modellernas klassificeringsförmåga.

Tabell 1: Initial jämförelse baserat på accuracy

Modell	Accuracy
LR	0,891
RF	0,970
HGB	0,864
CatBoost	0,972
Voting	0,954

Enligt tabell 1 uppvisade samtliga modeller god prediktionsförmåga, med accuracy-värden mellan 0,881 och 0,972.

Modellernas Confusion matrices i tabellform , tabell 2

Modell	TN	FP	FN	TP	Kommentarer
LR	12 241	1484	154	1121	
RF	12 452	1273	122	1153	
HGB	11765	1960	77	1198	
CB	12 430	1295	100	1175	God balans mellan falskt negativa och falskt positiva klassificeringar.
Voting	13 297	428	261	1014	

Trots att Random Forest och Histogram Gradient Boosting uppvisade hög accuracy prioriterades modellerna inte i den fortsatta analysen. Båda modellerna genererade ett betydligt större antal falskt negativa klassificeringar än CatBoost och Logistic Regression, vilket innebar att fler positiva diabetesfall förblev oupptäckta. Eftersom studiens syfte var att identifiera så många positiva fall som möjligt bedömdes dessa modeller som mindre lämpliga, trots deras starka resultat enligt accuracy-måttet.

Eftersom studiens huvudsakliga mål var att identifiera positiva observationer analyserades även antalet falskt negativa klassificeringar för respektive modell. Logistic Regression uppvisade lägst antal falskt negativa klassificeringar men genererade samtidigt ett stort antal falskt positiva klassificeringar. Voting Classifier uppnådde hög recall vid låga tröskelvärden men led av samma problematik. CatBoost uppvisade något fler falskt negativa klassificeringar än Logistic Regression, men betydligt färre falskt positiva klassificeringar, vilket resulterade i den mest balanserade kombinationen av recall och precision.

4.1 Hantering av klassobalans via balanserade klassvikter

Eftersom datasetet uppvisar en kraftig klassobalans (enbart 8,5 % positiva diabetesfall) visade en initial utvärdering baserad på standardhyperparametrar att modeller som Histogram Gradient Boosting (HGB) tenderade att prioritera majoritetsklassen. Detta resulterade i en hög övergripande pricksäkerhet (Accuracy) men ett oacceptabelt högt antal falskt negativa prediktioner (Typ II-fel), vilket i en klinisk screeningkontext innebär att sjuka individer förblir oupptäckta.

För att systematiskt styra modellernas beteende mot att prioritera identifieringen av den positiva minoritetsklassen valdes metodiken att integrera balanserade klassvikter (sample_weight) direkt under modelltilldelningen och hyperparameteroptimeringen med Optuna. Genom att tilldela en högre statistisk vikt till minoritetsklassen straffas felklassificeringar av diabetesfall betydligt hårdare under algoritmens minimeringsprocess.

I kombination med att Optuna-studien instruerades att explicit maximera känsligheten (Recall) som objektiv funktion, uppnåddes en markant förändring i modellernas prestandaprofil.

Modellens ökade känslighet tvingar fram den inneboende matematiska dragkampen i ett obalanserat datarum; den höga sensitiviteten leder oundvikligen till en ökning av antalet falska alarm (1 859 False Positives), vilket pressar ner Precision till 39,09 % och Accuracy till 87,06 %. Ur ett screeningperspektiv bedöms dock denna avvägning som optimal, då målet är att minimera risken för underdiagnostik.

4.2 Sammanfattande resultat

Resultaten visar att accuracy inte ensamt är ett lämpligt mått för modellval vid klassobalanserade datamängder. Modeller som uppvisade mycket hög accuracy visade samtidigt ett stort antal falskt negativa klassificeringar vid standardtröskeln 0,50.

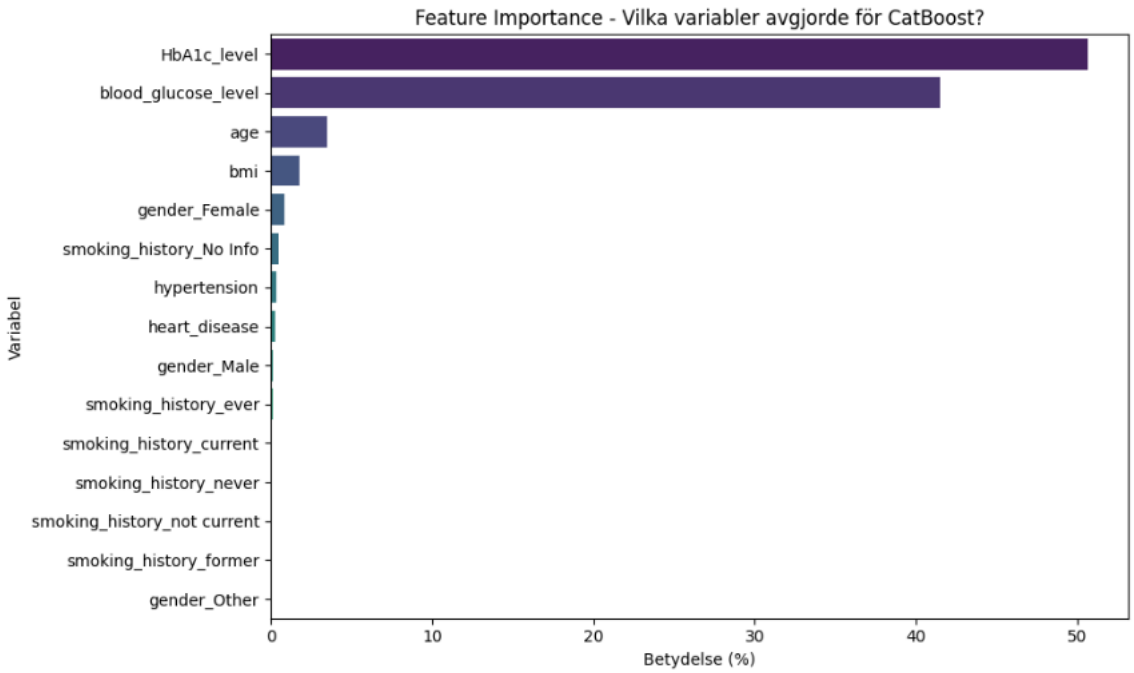
Efter vikt optimering med Optuna, uppvisade CatBoost den bästa balansen mellan identifiering av positiva observationer och begränsning av falskt positiva klassificeringar. HistogramGradientboosting hade lägst antal false negative, men till priset av ett betydligt större antal falskt positiva klassificeringar

Prestandamått (Metric)	Medelvärde (Mean)	95 % Konfidensintervall (95 % CI)	(Mean ± Std/CI)
Accuracy	0,9685	[0,9673 – 0,9697]	0,9685 ± 0,0012
Precision	0,9402	[0,9328 – 0,9476]	0,9402 ± 0,0074
Recall	0,8473	[0,8393 – 0,8552]	0,8473 ± 0,0079
F1-score	0,8870	[0,8821 – 0,8919]	0,8870 ± 0,0049

4.3 Variabelbetydelse (Feature Importance)

För att identifiera vilka faktorer som hade störst betydelse för modellens prediktioner analyserades CatBoost-modellens inbyggda mått för variabelbetydelse (Feature Importance). Analysen visade att HbA1c_level och blood_glucose_level dominerade modellens prediktioner med vikter på 50,63 % respektive 41,48 %. Tillsammans svarade dessa variabler för 92,11 % av debetydelsen.

Resultatet indikerar att modellens prediktioner i huvudsak baseras på de två starkaste kliniska indikatorerna för diabetes. Variabler som ålder (3,50 %) och BMI (1,80 %) bidrog i betydligt mindre utsträckning, medan rökstatus och kön hade marginell betydelse (under 1 % vardera).



4.4 Cross-validation och stabilitetsanalys för CatBoost

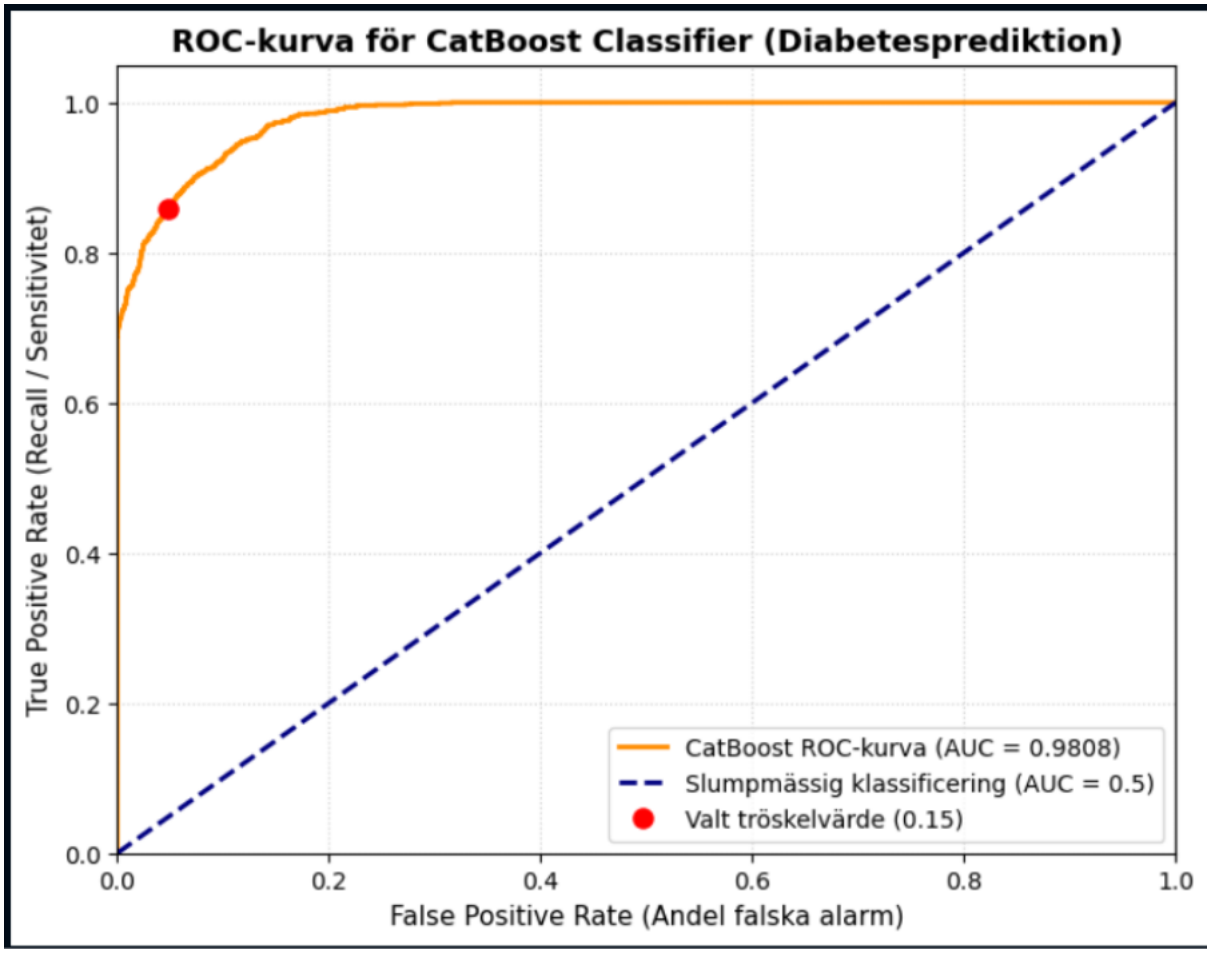
För att säkerställa att CatBoost-modellens starka prestanda är robust och inte ett resultat av en enskild, slumpmässig uppdelning av tränings- och testdata, genomfördes en 5-fold cross-validation på träningsmängden. Genom att dela upp datasetet i fem unika delar (*folds*) och iterativt träna samt utvärdera modellen fem gånger, erhålls en statistiskt tillförlitlig bedömning av modellens generaliseringsförmåga.

Resultatet från denna validering (se tabell) visar på en utomordentligt stabil och jämn prestandiprofil över samtliga folds:

Den **låga standardavvikelsen** över samtliga utvärderingsmått (exempelvis endast ±0,0040 för Recall) är av stor metodologisk betydelse. Det bevisar svart på vitt att modellen har en mycket låg varians och inte lider av överanpassning (*overfitting*). Modellens förmåga att korrekt identifiera diabetesfallen är med andra ord helt oberoende av hur datamaterialet

slumpas, vilket ger slutmodellen en stabil och tillförlitlighet och en robust generaliseringsförmåga på framtida, osedd data.

	Fold	Accuracy	Precision	Recall	F1-score
0	0	0.944929	0.811374	0.876909	0.840024
1	1	0.940000	0.796611	0.878027	0.830749
2	2	0.942000	0.803006	0.872260	0.832919
3	3	0.943357	0.805719	0.883292	0.838702
4	4	0.939286	0.795064	0.872682	0.827841
5	Mean	0.941914	0.802355	0.876634	0.834047
6	Std	0.002086	0.005987	0.004027	0.004649



Figur 6: *ROC-kurva för CatBoost-modellen vid diabetesprediktion.*

Modellen uppvisar ett högt AUC-värde på 0,9808, vilket tyder på en utmärkt diskrimineringsförmåga. Den röda markeringen visar modellens prestanda vid det optimerade tröskelvärdet 0,15. Vid denna punkt uppnås en hög True Positive Rate (Recall) på ca 85,8 % samtidigt som False Positive Rate (andel falska alarm) hålls mycket låg (ca 5 %).

För att säkerställa modellens statistiska stabilitet och verifiera att prestandan inte beror på slumpmässiga mönster genomfördes ett permutationstest (Figur X). Det observerade ROC-AUC-värdet uppgick till 0,9808, medan det högsta AUC-värdet som uppnåddes under

permutationerna med slumpad målvariabel stannade på 0,4091. Resultatet gav ett empiriskt p-värde på < 0,005, vilket ger ett starkt statistiskt stöd för att CatBoost-modellen har identifierat faktiska, strukturella samband i datamaterialet och besitter en stabil generaliseringsförmåga.

4.5 Besvarande av frågeställningar

1. Hur presterar binära klassificeringsmodeller på ett obalanserat, syntetiskt dataset, med fokus på hur klassobalansen påverkar valet av utvärderingsmått och beslutströskel?

De utvärderade modellerna uppvisar en mycket hög initial prestanda i form av *accuracy* (över 97 % för de träd-baserade modellerna). Den kraftiga klassobalansen (8,5 % positiva fall) gör dock att accuracy blir ett direkt missvisande mått. En modell kan uppnå hög precision genom att nästan uteslutande förutsäga majoritetsklassen (friska individer), vilket leder till ett farligt högt antal Typ II-fel (falskt negativa) där sjuka individer förblir oupptäckta.

Klassobalansen tvingar därför fram ett skifte i beslutströskel. Genom att överge standardtröskeln på 0,50 till förmån för en beslutsteoretiskt motiverad tröskel på 0,15, kan modellernas beteende anpassas. För slutmodellen CatBoost innebär denna tröskeljustering att modellens sensitivitet (Recall) maximeras till 85,8 %. Detta minimerar risken för kritiska Typ II-fel där det medicinska risktagandet är som störst, och flyttar fokus från blind övergripande exakthet till praktisk klinisk nytta.

2. Hur påverkar klassobalansen modellernas precision, recall, F1-värde och ROC-AUC, och vilka mått ger en rättvis bild av prestandan?

Klassobalansen skapar en inneboende matematisk dragkamp mellan *precision* och *recall* vid justering av beslutsgränsen. När tröskeln sänks för att fånga upp fler positiva fall (högre recall), ökar oundvikligen antalet Typ I-fel (falska positiva), vilket pressar ner precisionen. För CatBoost resulterar tröskeln 0,15 i en precision på 62,8 %. Detta innebär en förväntad ökning av falska larm, men nivån hålls tillräckligt kontrollerad för att screeningverktyget ska förbli användbart.

För att få en rättvis och nyanserad bild av prestandan under klassobalans krävs en kombination av följande mått:

- **ROC-AUC:** Ger en robust, tröskeloberoende bild av modellens övergripande förmåga att separera klasserna. CatBoosts höga värde på 0,9808 indikerar en god diskrimineringsförmåga.
- **F2-score:** Det absolut mest rättvisa måttet för denna kontext, eftersom det matematiskt viktar recall dubbelt så högt som precision. CatBoost maximerar detta mått till 0,800 vid tröskeln 0,15.
- Stabilitetsmått (Cross-validation): Genom att utvärdera makro-F1 över 5 folds och påvisa en extremt låg standardavvikelse 0,0049 för F1, ges det vetenskapliga beviset för att modellen är stabil och att resultatet inte är en produkt av slumpmässig överanpassning till en enskild datadelning.

5.0 Diskussion

I denna studie har fem olika maskininlärningsmodeller utvärderats på ett kraftigt obalanserat, syntetiskt diabetesdataset där endast 8,5 % av observationerna tillhörde positiv klass. Resultaten belyser den fundamentala utmaningen med klassobalans och visar tydligt att traditionella prestandamått som *accuracy* är otillräckliga. Modeller som Random Forest och Histogram Gradient Boosting uppvisade mycket hög initial accuracy (över 97 %), men en djupare analys av felklassificeringsmatriserna avslöjade att de missade ett stort antal faktiska diabetesfall vid standardtröskeln 0,50. I en hypotetisk klinisk screeningmiljö skulle detta innebära en oacceptabelt hög risk för underdiagnostik.

Genom en systematisk tröskeloptimering justerades beslutsgränsen för att prioritera *recall* och minimera de falskt negativa fallen, med *F2-score* som primärt optimeringsmått. CatBoost-modellen utkristalliserade sig som den bäst lämpade algoritmen. Vid beslutströskeln 0,15 uppnådde modellen ett F2-värde på 0,800, med en recall på 85,8 % och en precision på 62,8 %. Modellen uppvisade dessutom en utmärkt diskrimineringsförmåga med ett ROC-AUC-värde på 0,9808. Genom ett permutationstest och 5-fold cross-validation med snäva konfidensintervall har modellens statistiska stabilitet kunnat säkerställas, vilket bevisar att prestandan reflekterar faktiska strukturella mönster i datamaterialet snarare än slumpmässiga variationer.

En central metodologisk begränsning i detta projekt är datamaterialets syntetiska natur. Som beskrivits i rapportens introduktion saknar datasetet klinisk kontext, innehåller medicinskt osannolika BMI-värden och uppvisar trunkerade HbA1c-nivåer, vilket också har uppmärksammats i vetenskaplig litteratur (bland annat i *Nature*). Feature Importance-analysen bekräftar detta genom att visa att modellen nästan uteslutande (till över 92 %) förlitar sig på de två variablerna HbA1c_level och blood_glucose_level. I verkliga kliniska populationer är biologiska samband betydligt mer komplexa och multivariata. Resultaten i denna rapport ska därför strikt tolkas som en metodjämförelse under kontrollerade förhållanden och är inte automatiskt generaliserbara till faktiska patientgrupper.

6.0 Slutsats

Projektets centrala frågeställningar har besvarats genom att demonstrera hur klassobalans snedvrider standardiserade utvärderingsmått och hur justering av beslutströsklar kan användas för att anpassa en modells beteende efter specifika verksamhetsmål. De huvudsakliga slutsatserna från studien är:

- Accuracy är missvisande vid klassobalans: Hög total pricksäkerhet kan maskera en farligt låg förmåga att identifiera minoritetsklassen, vilket gör fel-klassificeringsmatriser, recall och F-mått nödvändiga för en rättvis utvärdering.

- CatBoost lämpad för uppgiften: Bland de utvärderade modellerna uppvisade den Optuna-optimerade CatBoost-modellen den mest robusta och stabila prestandan, stöttad av rigorösa statistiska kontroller såsom cross-validation och permutations-test.

Framtida arbete bör fokusera på att applicera samma metodologiska ramverk på validerade, realmedicinska dataset för att undersöka hur väl de avancerade trädmodellerna presterar när de ställs inför verkligt brus, saknade värden och komplexa kliniska kovariater.