

Projektbeskrivning Data science projekt

Maskininlärning från grunden: matematisk modellering av binär klassificering

Inledning

Modern maskininlärning vilar i grunden på binära strukturer. Från Booles logik till dagens sannolikhetsbaserade modeller bygger klassificering på att uppskatta sannolikheten för två möjliga tillstånd. Denna princip återkommer i en rad tillämpningsområden: kreditrisk, kundbeteende, marknadsanalys och medicinska prediktioner. Trots att domänerna skiljer sig åt är den matematiska kärnan densamma: att modellera ett binärt utfall som en sannolikhet mellan 0 och 1.

I detta projekt behandlas binär klassificering inte som ett absolut beslut, utan som en kontinuerlig sannolikhetsmodell. Arbetet genomförs iterativt och utforskande, där teori, implementation och analys utvecklas parallellt i korta cykler.

Syfte

Syftet är att undersöka hur binär klassificering kan modelleras matematiskt från grunden i Python, utan att använda färdiga maskininlärningsbibliotek. Projektet jämför egenutvecklade modeller med motsvarande implementationer i scikit-learn för att analysera skillnader i beteende, stabilitet och tolkbarhet. Ett ytterligare syfte är att experimentera med hybridmodeller för att studera hur kombinationer av matematiska principer påverkar prediktionsförmåga och transparens.

Frågeställningar

Projektet utgår från följande centrala frågor:

- Hur kan binär klassificering formuleras matematiskt på ett transparent och implementerbart sätt utan färdiga ML-bibliotek?
- Hur skiljer sig beteendet mellan egenutvecklade modeller och etablerade implementationer i scikit-learn?
- Vilka effekter uppstår när olika matematiska modeller kombineras till hybridansatser?
- Hur påverkar sannolikhetsformuleringen (0–1) tolkbarhet, stabilitet och prediktionsförmåga?
- Vilka insikter uppstår när teori och praktik utvecklas iterativt i en agil arbetsprocess?

Datamaterial och förberedelser

Som empiriskt underlag används *Diabetes Prediction Dataset* från Kaggle, vilket lämpar sig väl för binär klassificering. Datat genomgår grundläggande EDA, rensning och variabelhantering för att säkerställa att modellerna kan jämföras på ett metodologiskt korrekt sätt.

Metod

Arbetet bygger på matematisk modellering, stegvis implementation i Python och statistisk utvärdering. Projektet följer ett agilt arbetssätt där teori, kod och analys utvecklas i korta iterationer.

Train/test-upplägg

Datasetet delas i en 70/30-fördelning för att möjliggöra en rättvis och reproducerbar utvärdering. Samma train/test-split används för både egenutvecklade modeller och scikit-learn-modeller.

Modellering

Fyra modeller implementeras matematiskt från grunden:

- **Logistisk regression** – egen kostnadsfunktion, gradient och sigmoid.
- **K-Nearest Neighbors (KNN)** – egen distansfunktion och majoritetsregel.
- **Naive Bayes** – egna sannolikhetsberäkningar och oberoendeantaganden.
- **Decision Tree** – egen entropi/Gini-beräkning och rekursiv split-logik.

Modellerna byggs stegvis med ökande antal variabler (1, 3, 5, 7 och 9) för att analysera hur komplexitet påverkar konvergens och prediktionsförmåga.

Hybridexperiment

Som ett explorativt moment kombineras Naive Bayes och Decision Tree i en enkel hybridmodell för att studera hur två matematiskt olika principer samverkar.

Jämförelse med scikit-learn

Motsvarande modeller implementeras i scikit-learn och tränas på samma data. Jämförelsen fokuserar på skillnader i prestanda, stabilitet, konvergens och tolkbarhet.

Statistisk utvärdering

Prestanda utvärderas med accuracy, precision, recall, F1-värde och ROC-kurvor. För den bäst presterande modellen beräknas även konfidensintervall för att bedöma stabilitet.

Avgränsningar

Projektet fokuserar på grundläggande modellstruktur och sannolikhetsbaserat beteende. Hyperoptimering, ensemble-metoder och produktionssättning ingår inte. Syftet är att skapa en transparent och teoretiskt förankrad förståelse för modellernas matematiska uppbyggnad.